

● FLIGHTTRACKER

PLATAFORMA DATAOPS PARA MONITOREO DE TRÁFICO AEREO

ARQUITECTURA

Agustín Figueroa

Terraform y API

STREAMING

Gabriela Martínez

Streaming y eventos

BATCH

Juan Carlos Muñoz

Batch y Spark

GOBERNANZA

Juan Simón Ospina

Gobernanza y calidad

EQUIPO, PROYECTO Y CONTEXTO

FASES 2 · 3 · 4 · 5 · 9

PROBLEMA

>\$11.000M

Pérdidas anuales por retrasos y cancelaciones.

No existe una plataforma unificada que integre lo histórico, lo maestro y lo operativo.

SOLUCIÓN

FlightTracker integra datos históricos (BTS), maestros (OpenFlights) y en tiempo real (OpenSky) para KPIs, alertas y API.

PRODUCTOS DE DATOS ESPERADOS

Históricos de puntualidad por aerolínea y ruta	Vuelos activos en tiempo real
API REST	Dashboards

METODOLOGÍA

Fases 2, 3, 4, 5 y 9 del proyecto, cubiertas en este Sprint.

ALCANCE Y OBJETIVOS VERIFICABLES

OBJETIVO	DESCRIPCIÓN	ESTADO	EVIDENCIA
Ingesta batch	BTS cargado, validado y persistido en Firestore vía Pub/Sub	CUMPLIDO	flights_v1 · GET /flights
Capa Gold	Modelo estrella en BigQuery con integridad	CUMPLIDO	fact_flights (542.695 únicos) + 3 dimensiones + agregados
Calidad medida	Perfilamiento ejecutado con DQ scores	PARCIAL	dq_summary.csv – BTS/OpenFlights OK; OpenSky pendiente
Esqueleto live	Ruta OpenSky validada extremo a extremo	CUMPLIDO	GET /live/flights – la conectividad real es el primer ítem de Sprint 2

INVENTARIO DE FUENTES


BATCH · MAESTRO · LIVE

MODO	FUENTE	CONTENIDO	VOLUMEN	FRECUENCIA
BATCH	BTS	On-Time Performance, enero 2026 · CSV · datos reales	545.003	mensual
MAESTRO	OpenFlights airports	Maestro de aeropuertos · CSV · datos reales	7.698	estático
MAESTRO	OpenFlights airlines	Maestro de aerolíneas · CSV · datos reales	6.162	estático
LIVE	OpenSky Network	Estados por icao24 · JSON · esqueleto validado	~13.155	cada 5 min

PERFILAMIENTO Y CALIDAD


DQ_SUMMARY.CSV

BTS 0.9725



544.003 filas · sin nulos en columnas clave

OpenFlights airports 0.9999




7.698 filas

OpenFlights airlines 0.7195



6.162 filas · completitud 24,93 % (limitación de la fuente)

OpenSky 1.0



0 filas · sin datos reales para perfilar

HALLAZGOS

BTS sin nulos en columnas clave y fechas normalizadas.

Aerolíneas con baja completitud en campos del maestro.

OpenSky sin registros: la calidad no es medible en este Sprint.

ARQUITECTURA FLIGHTTRACKER – SPRINT 1




Diagrama de almacenamiento (hecho después del feedback del profesor)

ESTRUCTURA DE ALMACENAMIENTO – FLIGHTTRACKER SPRINT 1



Cloud Storage (Data Lake)

Bronze (RAW)

Archivos CSV originales del BTS
545,003 registros • 55.78 MiB



Silver (Limpio y Normalizado)

Archivos Parquet particionados por año/mes



Gold (Modelo Estrella)

Archivos Parquet listos para análisis (modelo estrella)



Firestore (Operacional)

Colección: flights_v1 (batch)



ID: flight_id (hash único)

Campos clave:

- carrier
- flight_number
- origin
- dest
- dep_delay
- arr_delay
- cancelled

Documento por flight_id

Colección: live_flights (near-real-time)



ID: icao24 (código de aeronave)

Campos clave:

- callsign
- latitude
- longitude
- altitude
- velocity
- timestamp

Documento por icao24



Cloud SQL (Maestros) (PostgreSQL)

Tabla: airlines

Columna	Descripción
airline_key (PK)	Clave única de aerolínea
iata_code	Código IATA (2 letras)
name	Nombre de la aerolínea
country	País de la aerolínea

Tabla: airports

Columna	Descripción
airport_key (PK)	Clave única de aeropuerto
iata_code	Código IATA (3 letras)
name	Nombre del aeropuerto
city	Ciudad
country	País
lat	Latitud
lon	Longitud



BigQuery (Warehouse)

Dimensión dim_airline (1,121 filas)

- airline_key (PK)
- iata_code
- name
- country

Dimensión dim_date (31 filas)

- date_key (PK)
- date
- day_of_week
- month
- year

Tabla de Hechos fact_flights (542,695 filas)

- flight_id (PK)
- date_key (FK)
- airline_key (FK)
- origin_key (FK)
- dest_key (FK)
- dep_delay
- arr_delay
- cancelled

Dimensión dim_airport (6,073 filas)

- airport_key (PK)
- iata_code
- name
- city
- country
- lat
- lon

Tablas de Agregados (KPIs)

agg_on_time_performance
(desempeño a tiempo)

agg_delay_distribution
(distribución de retrasos)

DECISIONES Y TRADE-OFFS

DECISIÓN 01

FIRESTORE COMO SERVING TEMPORAL

Servicio administrado, cierre rápido.

COSTO

Migración a Cassandra en Sprint 2.

DECISIÓN 02

IDEMPOTENCIA CON FLIGHT_ID DETERMINÍSTICO

Pub/Sub entrega al menos una vez; la clave se deriva del contenido.

COSTO

Cambios de esquema obligan a versionar el hash.

DECISIÓN 03

DATAPROC EFÍMERO POR EJECUCIÓN


Ahorro de costos y configuración en código.

COSTO

Latencia de arranque en cada corrida.

MODELADO CONCEPTUAL Y LÓGICO

Modelado Conceptual y Lógico – FlightTracker





NOTAS IMPORTANTES

- Los hashes SHA-256 garantizan idempotencia y trazabilidad en el pipeline.
- flight_id** es la clave primaria en **fact_flights** (BigQuery).
- icao24** permite sobrescribir estados en **live_flights** (Firestore).
- event_id** y **flight_id** se generan en la Cloud Function **split_and_publish_bts**.
- icao24** proviene directamente de los datos de OpenSky.

- Entidades principales del negocio (light blue box)
- Entidades de evento / proceso (light grey box)
- Identificadores clave (modelo lógico) (light green box)


MODELO FÍSICO - GOLD EN BIGQUERY

MODELO ESTRELLA



FLUJO DE INGENIERÍA DE DATOS

RAMA BATCH



RAMA LIVE · ESQUELETO VALIDADO



13.155 estados por snapshot · conectividad real pendiente para Sprint 2

TRANSFORMACIONES Y EVIDENCIA

TRANSFORMACIÓN	EVIDENCIA
build_flight_id()	542.695 filas = 542.695 IDs distintos
Normalización de hash	0 IDs nulos en Gold
Deduplicación de dimensiones	1.121 + 6.073 + 31 filas
Joins con broadcast	Plan de ejecución optimizado
Limpieza BTS	Filtrado de nulos y conversión de fechas

INFRAESTRUCTURA COMO CÓDIGO

REPRODUCIBILIDAD PARCIAL

SCRIPTS

```
bootstrap.sh  
deploy.sh  
validate.sh  
destroy.sh
```

Terraform con módulos para todos los recursos y estado remoto en GCS.

EXCEPCIONES MANUALES DOCUMENTADAS

Subida del CSV BTS

Manual, por gsutil.

Snapshot de OpenSky

Manual, por timeout.

Drift en validate_and_persist_bts

Conocido; se corregirá en Sprint 2.

REPRODUCIBILIDAD Y OPERACIÓN

VALIDATE.SH 10/10

```
$ git clone ...
$ bash bootstrap.sh --project-id flighttracker-505314
$ bash deploy.sh --skip-api-build
$ bash validate.sh
```

✓ 10/10 checks en verde

Secretos gestionados con Secret Manager para la contraseña de Cloud SQL; código endurecido.

ESTADO OPERATIVO

Validación automatizada IMPLEMENTADO

Secret Manager IMPLEMENTADO

Logs nativos de GCP IMPLEMENTADO

CI/CD (GitHub Actions) SPRINT 2

Monitoreo y alertas SPRINT 2

GOBERNANZA, OPTIMIZACIÓN Y CONSUMO

GOBERNANZA

- Perfilamiento: DQ scores > 0.95 en BTS y OpenFlights.
- Linaje: event_id por cada fila procesada (trazabilidad desde origen hasta Firestore).
- Catálogo de datos: Pendiente para Sprint 2 (OpenMetadata).

OPTIMIZACIÓN

- Clustering: BigQuery clusterizado por airline_key y date_key (menor costo).
- Agregados precalculados: KPIs en tablas agg_on_time_performance y agg_delay_distribution (dashboards <1s).
- Broadcast joins: Dimensiones pequeñas (1,121 + 6,073 + 31 filas) se difunden en Spark (evita shuffle).

CONSUMO

- API REST (Cloud Run):
 - /flights – Históricos desde Firestore.
 - /live/flights – Vuelos activos desde Firestore.
 - /stats – Métricas agregadas desde BigQuery.
- Grafana: Dashboards de KPIs (total, cancelaciones, puntualidad, top aerolíneas).
- Streamlit (opcional): Mapa de vuelos en tiempo real.

DEMO FUNCIONAL

EVIDENCIA EN EJECUCIÓN

VALIDATE.SH 10/10

```
figuesicsi@cloudshell:~/Sicard (flighttracker-505314)$ bash infrastructure/scripts/validate.sh --project-id flighttracker-505314
[validate] Active gcloud account: figuesicsi@gmail.com
Updated property [core/project].
[validate] Environment label: dev
[validate] Project id      : flighttracker-505314
[validate] Data region    : us-centrall
[validate] Batch region   : us-east1
[validate] API region     : us-centrall
PASS terraform validate
PASS api health
PASS api flights
PASS api live flights
PASS pubsub topic exists
PASS firestore collection probe
PASS bigquery gold fact rows
PASS latest dataproc job visible
PASS scheduler job exists
PASS dq report presence
[validate] Validation completed successfully with all checks passing.
figuesicsi@cloudshell:~/Sicard (flighttracker-505314)$
```

CURL /FLIGHTS?LIMIT=5


```
figuesicsi@cloudshell:~/Sicard (flighttracker-505314)$ curl -s "https://get-flights-api-oxdhaiwca-uc.a.run.app/flights?limit=5" | jq '.'
{
  "status": "success",
  "count": 5,
  "data": [
    {
      "CANCELLATION_CODE": "",
      "dep_time": 1059,
      "arr_time": 21.0,
      "carrier": "AA",
      "flight_id": "000055fe6490e45f4909e9d2a0843dc16a1092c22bb16f6ab42d8510645cd947",
      "distance": 101.0,
      "DEP_TIME": 1059,
      "processed_at": "2026-08-26T03:23:21.670102+00:00",
      "source_generation": "178769246059348",
      "OP_CARRIER_FL_NUM": "1003",
      "destination": "HNL",
      "cancelled": false,
      "DEST": "HNL",
      "flight_number": "1003",
      "AIR_TIME": 21.0,
      "source_uri": "gs://flighttracker-xaw-bce/bce/demo_20260825_211345.csv",
      "source_row_number": 252027,
      "event_id": "f6a4d52ac57b3409a4224623090b61e185ed4d6b47e609d19d65f6c38463c2d",
      "origin": "OOS",
      "OP_CARRIER": "AA",
      "DEP_DELAY": 23.0,
      "arr_time": 1146,
      "CANCELLED": false,
      "arr_delay": 27.0,
      "DISTANCE": 101.0,
      "FL_DATE": "2026-01-15",
      "schema_version": "Flight curated.v1",
      "ARR_TIME": 1146,
      "ORIGIN": "OOS",
      "flight_date": "2026-01-15",
      "ARR_DELAY": 27.0,
      "dep_delay": 23.0
    },
    {
      "CANCELLATION_CODE": "",
      "dep_time": 645,
      "arr_time": 136.0,
      "carrier": "DL",
      "flight_id": "00006dcd468a69289301281920da6557f23a30159e232630180ae3d2787d3dca",

```

GRAFANA · KPIS



STREAMLIT



VALIDACIÓN POR TERCEROS

CHECKLIST DE ACEPTACIÓN

QUIÉN VALIDA

Un compañero de otro grupo (por asignar) y el profesor durante la sustentación.

INSTRUMENTO

Checklist basado en los criterios de aceptación.

CÓMO SE INCORPORA

Observaciones registradas en el backlog de Sprint 2 y priorizadas.

QUÉ SE VALIDA

- ☐ Reproducibilidad — clonar el repo y correr los scripts
- ☐ Funcionalidad — API y consultas en BigQuery
- ☐ Calidad — reportes DQ
- ☐ Arquitectura — decisiones documentadas

APRENDIZAJES Y PLANEACIÓN SPRINT 2

APRENDIZAJES

- La arquitectura desacoplada funciona.
- La idempotencia es clave en el pipeline.
- La reproducibilidad quedó validada.
- OpenSky es el principal desafío pendiente.

#	DEUDA	TAREA SPRINT 2	RESP.
01	OpenSky sin datos reales	Resolver conectividad y activar la rama live	Martínez
02	opensky-producer no versionado	Versionar y redeployar desde el repo	Martínez
03	Drift de Terraform	Fijar la región en código	Figueroa
04	Bucket con control de acceso legacy	Migrar a control uniforme	Ospina
05	Sin perfilamiento de OpenSky	Perfilar live_flights con datos reales	Ospina
06	CI/CD no implementada	Llevar validate.sh a un pipeline de GitHub Actions	Muñoz

Crítico Medio

PLANEACIÓN SPRINT 2

Backlog priorizado, hitos por semana y criterios de aceptación.